

mid_order_ratio — Single Factor Research Report

Research status: Completed factor construction audit, standalone predictive validation, robustness testing, and exposure diagnostics.

mid_order_ratio measures the fraction of daily traded amount contributed by trades with transaction amount between RMB 40k and RMB 200k.


Research universe

Sample: 2023-01-04 to 2024-06-28 • 358 days | Universe: CSI1000 PIT • avg. 990 valid names
Signal lag: T-1 factor | Return horizon: next-day close-to-close
Factor data: ClickHouse strict L2 Tick | Reference data: DolphinDB Wind

Table 1 — Standalone Factor Performance Summary

Metric	Result	Interpretation
RankIC	Raw -4.80% • effective +4.80%	Higher raw factor predicts lower return rank
ICIR	Raw -6.33 • effective +6.33	Sign follows factor orientation
IC t-stat	-7.58	Sample mean differs from zero
IC negative days	67.9%	Not driven only by a few dates
Effective H-L Sharpe	2.74 gross	Standalone sorting diagnostic; fee=0
H-L MDD	-9.68%	Compounded diagnostic path
H-L turnover	1.69 / day	High turnover; costs not modeled

Figure 1 — Factor construction pipeline



Tick data -> strict transaction filtering -> trade-size bucket -> daily factor -> next-day return

Figure 2 — Universe comparison

Raw-factor RankIC direction is negative in SSE/SZSE A-share (excluding BSE), CSI300, CSI500, and CSI1000. H-L metrics are standalone sorting diagnostics.

mid_order_ratio — Point-in-Time Universe Comparison							
RankIC is raw direction; H-L is effective direction and exact-universe-EW excess							
Universe	Avg names	Date range	RankIC	ICIR	H-L Sharpe	H-L MDD	H-L TO
SSE/SZSE A	4,840	2023-01-04 2024-06-28	-5.53%	-7.29	3.05	-20.51%	1.73
CSI300	299	2023-01-04 2024-06-28	-2.12%	-3.34	1.26	-9.90%	1.68
CSI500	497	2023-01-04 2024-06-28	-3.45%	-4.43	1.49	-9.57%	1.72
CSI1000	990	2023-01-04 2024-06-28	-4.80%	-6.33	2.74	-9.68%	1.69

Source: OH strict-trade L4s/100w cache + Wind PIT membership/returns + daily c2c + T-1 signal + 2023-01-01 to 2024-06-30.

Figure 2. Same strict-trade definition, T-1 signal, and PIT membership rules.

Universe	RankIC	ICIR	H-L Sharpe	MDD	Turnover
ALL	-5.53%	-7.29	3.05	-20.51%	1.73
CSI300	-2.12%	-3.34	1.26	-9.90%	1.68
CSI500	-3.45%	-4.43	1.49	-9.57%	1.72
CSI1000	-4.80%	-6.33	2.74	-9.68%	1.69

Interpretation: signal direction is consistent across universes, while magnitude varies by market-cap segment.

Figure 3 — CSI1000 index-excess decile diagnostic

Effective signal = `-mid_order_ratio`; T-1 signal; cumulative sum of next-day CSI1000 index-excess returns.
This is a standalone sorting diagnostic.




Figure 3. Tails separate clearly; middle deciles are not perfectly monotonic.

Decile	Annualized excess	Raw-factor meaning
G1	-30.07%	highest <code>mid_order_ratio</code>
G2	-15.51%	higher
G3	3.89%	
G4	8.21%	
G5	5.95%	
G6	11.48%	
G7	10.48%	
G8	10.22%	
G9	12.05%	lower
G10	11.05%	lowest <code>mid_order_ratio</code>

Figure 4 — IC stability

Daily raw RankIC, 63-trading-day rolling mean, and monthly averages test whether the relationship is concentrated in a small number of dates.




Figure 4. Mean raw RankIC -4.80%; 16 of 18 monthly means are negative.

Mean RankIC	Negative months	Excluding 2024-01	Largest positive month
-4.80%	16 / 18	-4.79%	2024-02 • +3.10%

Figure 5 — Factor exposure diagnostics

Industry and size controls test whether common exposures fully explain the standalone predictive relationship. They are not additional alpha inputs.




Figure 5. Daily CSI1000 PIT cross-sectional residual diagnostics.

Method	RankIC	ICIR	H-L Sharpe	MDD
Raw	-4.80%	-6.33	2.74	-9.68%
Industry	-4.62%	-9.53	4.17	-6.62%
Market cap	-4.52%	-5.82	2.42	-10.05%
Industry + market cap	-4.41%	-9.09	4.42	-7.22%

Interpretation: industry and size explain part of the factor level, but do not fully explain the negative next-day RankIC.

Table of Contents

- 01. Executive Overview
- 02. 01 — Executive Summary
- 03. 02 — Data and Factor Construction
- 04. 03 — Standalone Signal Validation
- 05. 04 — Robustness Analysis
- 06. 05 — Factor Exposure Diagnostics
- 07. 06 — Economic Interpretation
- 08. 07 — Limitations and Future Research
- 09. 08 — Research Decision Framework
- 10. Appendix A — Code Reference
- 11. Appendix B — Data Lineage
- 12. Appendix C — Reproduction Commands

mid_order_ratio — Single Factor Research Report

Research status: Completed factor construction audit, standalone predictive validation, robustness testing, and exposure diagnostics.

Research positioning

本报告只验证：

mid_order_ratio 是否具有统计显著、稳健且可作经济解释的 standalone predictive power？

它不是因子组合、权重配置或生产化报告。

Factor definition

mid_order_ratio measures the fraction of daily traded amount contributed by trades with transaction amount between RMB 40k and RMB 200k.

原始因子与下一交易日收益排序呈负相关：

Direction	RankIC	ICIR	Interpretation
Raw mid_order_ratio	-4.80%	-6.33	因子值越高，次日收益排序越低
Effective -mid_order_ratio	+4.80% equivalent	+6.33 equivalent	用于 decile 与 H-L 的展示方向

负 ICIR 只反映 raw factor 的经济方向，不表示统计失效。

Research conclusion

1. Construction: 旧 Tick 查询的逐日时段和深市成交识别存在实质问题；正式结果已使用 strict-trade cache 重构；
2. Prediction: CSI1000 raw RankIC -4.80%，t-stat -7.58，67.9% 的交易日 IC 为负；
3. Robustness: 四股票池方向一致，25 个阈值单元全部为负 IC，16 / 18 个月平均 IC 为负；
4. Exposure diagnostics: 行业、市值、momentum、volatility 和 turnover 可以解释部分关系，但未在当前残差检验中完全解释；
5. Economic interpretation: 短期流动性压力与临时价格影响是候选机制，但主动方向、价格路径、因果和反转均未被当前结果识别；
6. Verdict: 该因子值得作为 research candidate / candidate alpha feature 继续进行更长历史和样本外验证。

Full report export

- Public single-file HTML — images embedded; open via browser link
- Local HTML — uses local MathJax assets
- PDF

Public HTML can be opened directly:

absolute file link


```
xdg-open "file://$(pwd)/research/reports/factors/mid_order_ratio/export/public/index.html"

# or serve a shareable http link on this machine
cd research/reports/factors/mid_order_ratio/export/public
python3 -m http.server 8765 --bind 0.0.0.0
# then open: http://<this-host>:8765/
```

```
/opt/conda/anaconda3/envs/base_93/bin/python \
l2_factor_reproduction/scripts/export_mid_order_ratio_report.py
```

Authoritative evidence

-
- Machine-readable results: artifacts/
 - Figures: figures/
 - Manifest: artifacts/artifact_manifest.json
 - Strict cache builder: l2_factor_reproduction/scripts/build_mid_order_ratio_strict_cache.py
 - Report artifact generator: l2_factor_reproduction/scripts/generate_mid_order_ratio_report_artifacts.py
 - Strict cache SHA256:

```
ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f
```

旧 factor_narrow.parquet 与严格面板的 Spearman 仅为 0.7996，保留为 audit comparison，不作为本报告结论依据。

Scope boundary

所有 Sharpe 均为 fee=0 gross sorting diagnostics。H-L 用于验证单因子横截面两端分离，不代表成本后结果。Further portfolio integration is outside the scope of this report.

01 — Executive Summary

Research status: Completed factor construction audit, standalone predictive validation, robustness testing, and exposure diagnostics.

1. Factor definition

mid_order_ratio measures the fraction of daily traded amount contributed by trades with transaction amount between RMB 40k and RMB 200k.

对股票 i 和交易日 t ，原始因子定义为：

$$\mathrm{MidOrderRatio}_{i,t} = \frac{\sum_k a_{i,t,k} \mathbf{1}(40,000 < a_{i,t,k} \leq 200,000)}{\sum_k a_{i,t,k}}$$

其中 $a_{i,t,k}$ 是严格识别后的第 k 笔成交金额。原始因子越高，下一交易日收益排序平均越低，因此用于分组展示的有效方向为 $-\text{mid_order_ratio}$ 。

4 万/20 万是本次样本验证前已冻结的既有研究口径，不是从当前样本挑选的最优参数。它用于刻画小额成交与 20 万元以上较大成交之间的中等成交规模构成；该区间在 CSI1000 PIT 样本中约占总成交额 30.2%，具有足够统计质量。金额阈值不识别交易者身份，不能机械解释为“散户”或“机构”标签。

2. Research question and scope

本报告只回答一个问题：

mid_order_ratio 是否具有统计显著、稳健且可作经济解释的独立单因子预测关系？

十分组与 H-L 仅用于检验横截面排序、尾部分离和路径稳定性。本报告不讨论因子组合、权重配置、优化或生产化。

3. Research universe

Item	Research specification
Sample period	2023-01-04 to 2024-06-28; 358 个有效交易日
Headline universe	CSI1000 Wind point-in-time constituents; 日均 990 只有效股票
Robustness universes	SSE/SZSE A-share (不含北交所)、CSI300、CSI500、CSI1000
Signal lag	1 个交易日; T-1 收盘后完整因子解释 T 日收益
Return horizon	下一交易日 close-to-close return
Factor data	ClickHouse SSE/SZSE Level-2 Tick, 严格成交筛选
Return and reference data	DolphinDB Wind 日收益、指数成分、行业、市值与可交易状态

4. Table 1 — Standalone Factor Performance Summary

Metric	Result	Interpretation
RankIC	Raw mid_order_ratio: -4.80%; effective -mid_order_ratio: +4.80% equivalent	原始因子越高，次日收益排名越低
ICIR	Raw: -6.33; effective: +6.33 equivalent	负号只表示原始因子方向； 取反后稳定性为正向等价值
IC t-stat	Raw: -7.58; effective: +7.58 equivalent	样本内均值显著偏离 0；未做 Newey-West 调整
IC negative day ratio	67.9%	原始方向多数交易日为负， 不由少数极端日单独贡献
Effective H-L Sharpe	2.74 gross	-mid_order_ratio 十分组两端差的独立排序诊断，fee=0
Effective H-L MDD	-9.68%	基于 H-L 日收益复利路径
Effective H-L turnover	1.69 per day	两端权重变化较高；交易成本尚未建模

Raw direction versus effective direction

Raw factor: mid_order_ratioRankIC = -4.80%

Effective signal: $-\text{mid_order_ratio}$ RankIC = +4.80% equivalent

ICIR、t-stat 和 IC 日占比遵循同一符号转换。报告保留 raw 结果以忠实表达经济关系，同时使用 effective direction 绘制从 G1 到 G10 的排序图，避免把“负 ICIR”误读为统计失效。

5. Construction audit finding

研究价值首先来自构造审计，而不是任何单一 Sharpe 数字。审计发现旧 Tick 查询存在两个实质问题：

1. 多日查询没有对每个交易日逐行施加常规交易时段条件；
2. 深市仅使用 `Type='011'`，未同时要求有效的买卖订单号来识别真实成交。

正式结果全部基于修正后的 `strict-trade cache`：

```
SSE: Type = 'T'  
SZSE: Type = '011' AND BidOrderNo > 0 AND AskOrderNo > 0  
Time: 09:30:00 <= ExchTime < 15:00:01 on every date
```

旧面板与严格面板的 Spearman 仅为 0.7996，因此旧结果未被沿用。严格 cache SHA256：

```
ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f
```

6. Evidence summary

- Statistical prediction: CSI1000 raw RankIC -4.80%，t-stat -7.58，16 / 18 个月平均 IC 为负；
- Cross-universe robustness: SSE/SZSE A-share、CSI300、CSI500、CSI1000 的 raw RankIC 均为负；
- Parameter robustness: 25 个合理阈值单元全部保持负 IC，未按样本内最高 Sharpe 改写定义；
- Exposure diagnostics: 行业、市值以及行业+市值残差的 RankIC 仍为负，预测关系不能被这些暴露完全解释；
- State dependence: 高换手状态中信号更强，说明强度随交易活跃环境变化；
- Economic interpretation: 结果与短期流动性压力、临时价格冲击等候选机制相容，但尚未验证主动方向与价格路径，不构成因果或反转识别。

前五页 evidence brief 依次展示：

1. factor construction pipeline；
2. universe comparison；
3. CSI1000 index-excess decile diagnostic；
4. daily / rolling / monthly IC stability；
5. industry and size exposure diagnostic。

7. Research verdict

Validation question	Verdict	Evidence boundary
1. Correctly constructed?	Yes, after material query corrections	严格交易所筛选、逐日时段过滤、冻结 cache、单元测试和数据血缘均可审计
2. Statistically predictive?	Yes, in the observed sample	RankIC、ICIR、t-stat、IC 日占比和 decile 尾部分离一致
3. Robust across reasonable tests?	Yes, within the available sample	四股票池、25 参数单元、时间与状态检验方向总体一致
4. Economically interpretable?	Plausible, not proven	与短期流动性压力和临时价格冲击一致；成交金额不能识别交易者身份
5. Worth further research?	Yes — research candidate	需要更长历史、样本外时期、更多 horizon 和方向性订单验证

综合判断：

本研究构造了一个具有可审计数据血缘的 L2 成交规模因子。该因子在当前样本中表现出统计显著的独立横截面预测关系，经多项合理稳健性检验后方向仍一致，并具有合理但未被证明的经济解释。它适合作为 candidate alpha feature 继续验证，不代表已完成长期样本外验证。

后续组合集成不在本报告范围内。

02 — Data and Factor Construction

1. 为什么必须使用 L2 Tick

不同频率的数据保留的信息不同：

日频 OHLCV

只知道一天的开高低收、总成交量和总成交额
无法回答“总成交额由多大的单笔成交组成”

分钟数据

知道每分钟价格与成交额
仍把一分钟内的许多成交压缩成一条 bar
只能构造平均单笔金额代理，不能恢复真实订单金额分布

Level-2 Tick

每一笔成交均保留时间、价格、数量和金额
可以逐笔分类后再聚合
因而可以直接计算中单成交额占比

mid_order_ratio 的研究对象不是价格或总成交量，而是总成交额的单笔金额构成。该信息在 OHLCV 和分钟 bar 聚合时已经丢失，事后无法精确恢复。

2. 数据源

ClickHouse 连接

- 配置：COMMON_CONST.DATA_DB_HFDATA
- host / port: 10.80.139.9:8123
- database: cmds
- 表：
 - cmds.SSE_AL_TICK_EXG
 - cmds.SZSE_AL_TICK_EXG

连接由 clickhouse_connect.get_client(**DATA_DB_HFDATA) 创建。账号信息不在报告中展开。

DolphinDB 连接

- 配置：COMMON_CONST.DATA_DB_CONN
- host / port: 10.12.180.9:8902
- 统一入口：core/ddb/connection.py::get_ddb_session

DolphinDB 不负责构造本因子；它提供 Wind 日收益、指数成分、ST/涨跌停/停牌、行业、市值和换手率。

3. 字段使用审计

本报告核验的 Tick 字段及其在本因子中的实际用途：

字段	本因子是否使用	用途
Price	是	深市单笔金额 $\text{Price} \times \text{Volume}$ ；同时过滤 $\text{Price} > 0$
Volume	是	与 Price 相乘；过滤 $\text{Volume} > 0$
Amount	仅上交所	上交所优先使用 Amount，缺失时回退 $\text{Price} \times \text{Volume}$
ExchTime	是	交易日、交易时段和聚合日期
BSFlag	否	可用于上交所主动买卖方向，但本因子不区分方向
BidOrderNo	是（深市筛选）	与 AskOrderNo 同时大于 0 时识别深市成交记录；不参与金额分档
AskOrderNo	是（深市筛选）	与 BidOrderNo 同时大于 0 时识别深市成交记录；不参与金额分档

这一区分很重要：mid_order_ratio 衡量成交规模结构，不是主动买卖方向。订单号用于判断深市记录是否为成交，不能省略；但买卖订单号的大小关系和 BSFlag 不进入因子数值。

4. 精确因子定义

对股票 i 、交易日 t 、成交 k ：

```
a_{i,t,k} = \begin{cases} \mathrm{ifNull}(\mathrm{Amount}, \mathrm{Price} \times \mathrm{Volume}), & \text{SSE} \\ \mathrm{Price} \times \mathrm{Volume}, & \text{SZSE} \end{cases}
```

```
\mathrm{MediumAmount}_{i,t} = \sum_k a_{i,t,k}, \\ \mathbf{1}_{(40,000 < a_{i,t,k} \leq 200,000)}
```

```
\mathrm{MidOrderRatio}_{i,t} = \frac{\mathrm{MediumAmount}_{i,t}}{\mathrm{TotalAmount}_{i,t}}
```

边界为左开右闭：

- 小于等于 4 万元不计入中单；
- 4 万元以上、20 万元以下或等于 20 万元计入；
- 20 万元以上不计入。

为什么使用 4 万至 20 万元

需要区分定义来源与经济解释：

- 1. 定义来源：〔4万， 20万〕是本项目在本次验证前已经存在并冻结的研究公式，不是从当前 2023-01 至 2024-06 样本中挑选出的最优区间。订单规模 family 的标准五档以 5 万和 20 万为相邻边界，额外保留 4 万累计边界是为了不静默改写既有 mid_order_ratio；
 - 2. 数据可用性： 在 CSI1000 PIT 样本中，该区间约占总成交额的 30.2%，具有足够横截面质量，不是由极少数尾部成交主导的稀疏桶；
 - 3. 研究直觉： 该区间刻画小额成交与 20 万元以上较大成交之间的中等成交规模构成，可能对执行方式和短期交易环境的变化敏感。这个直觉只用于提出待检验假说，不是阈值的因果证明。
- 邻近的 25 组阈值全部保持负 IC，支持的是“结论不依赖 4 万/20 万这一孤立点”，而不是“4 万/20 万在经济上最优”。由于逐笔金额不能识别账户、母订单或交易动机，报告不采用“4 万以下等于散户噪声、20 万以上等于机构交易”这类身份映射。

5. SQL 聚合逻辑

l2_factor_reproduction/python/ch_tick.py::fetch_tick_agg_by_date_range 的核心逻辑可概括为：

```
SELECT
  Symbol,
  toDate(ExchTime) AS TradeDate,
  sum(amt) AS TotalAmount,
  sum(if(amt > 40000 AND amt <= 200000, amt, 0)) AS MediumAmount
FROM tick_table
WHERE ExchTime in regular_session
  AND Price > 0
  AND Volume > 0
  AND exchange_specific_trade_filter
GROUP BY Symbol, TradeDate
```

交易所级成交过滤为：

```
SSE: Type = 'T'
SZSE: Type = '011' AND BidOrderNo > 0 AND AskOrderNo > 0
```

交易窗口为：

```
09:30:00 <= ExchTime < 15:00:01
timezone = Asia/Shanghai
```

该窗口条件现在对范围内每一行、每一个交易日显式施加。仅用 ExchTime >= start 09:30 和 ExchTime < end 15:00:01 只能约束区间首尾， 会让中间日期的盘前记录进入结果。

旧实现缺陷与修正影响

最初审计只比较了深市 Type='011' 与其他 Type，因其他类型几乎不存在而错误地判断影响很小。进一步核验发现，Type='011' 内仍同时包含非成交事件；必须要求买卖订单号均有效。

2024-06-27、697 只深市样本股的对照结果：

Check	Legacy positive-price/volume rows	Strict executions
Rows	29,836,521	11,916,224
Amount	RMB 370.77bn	RMB 93.19bn
Strict amount / legacy amount	—	25.13%

单日因子在两种口径下的 Spearman 相关为 0.858，平均绝对差为 8.64 个百分点。另一个时段审计显示，盘前/盘后记录占代表日金额约 2.52%。因此这不是文档层小风险，而是会改变构造的实质问题。

这些一次性查询结果已结构化保存为 artifacts/strict_trade_filter_audit.json。边界是：当时没有同时冻结精确股票列表和原始查询快照，因此该 JSON 是机器可读的 frozen audit record，不等同于完整可一键复算的原始证据。未来重跑时必须把 symbol list、SQL、原始结果和 checksum 一并落盘后再替换这些数字。

ch_tick.py 已同时修正：

1. 每个日期逐行施加 09:30:00 <= ExchTime < 15:00:01；
2. 深市限定 Type='011' 且买卖订单号均大于 0；
3. SSE、SZSE SQL 与边界公式增加无网络单元测试。

数据质量为什么会改变因子含义

这两个缺陷会同时污染分子和分母，但污染不会在比例中自动抵消：

```
intended numerator = amount of true trades in (40k, 200k]
intended denominator = amount of all true trades

legacy numerator / denominator
= true trades
+ non-trade events admitted by the SZSE filter
+ off-session rows admitted by the date-range filter
```

非成交事件和盘外记录的金额分布不必与真实成交相同，因此其进入分子与分母的比例也不必相同。此时结果即使仍落在 [0, 1]，也不再严格表示“真实成交中的中等金额占比”，而是混合事件的金额结构，原有经济标签随之失效。

代表日审计中，深市 strict amount 仅为 legacy amount 的 25.13%，单日因子 Spearman 为 0.858；全样本 legacy 与 strict 面板 Spearman 也只有 0.7996。这些差异说明数据治理不是形式检查，而是正式因子定义的一部分。


6. 为什么在 ClickHouse 内聚合

逐笔表的行数远高于股票日面板。若把 Tick 全量拉到 Python：

- 网络传输成为瓶颈；
- Python 内存占用随成交笔数增长；
- 中断后恢复成本高；
- 容易产生不同脚本各自实现分档的口径漂移。

将筛选、金额计算和 GROUP BY (Symbol, TradeDate) 下推后，Python 只接收每只股票每天一行的 TotalAmount / MediumAmount。严格报告缓存最终只有 1,805,656 个沪深 A 股股票日；原始逐笔记录不跨网络传到 Python。

7. 构造链路



Pipeline architecture

```
run_single_factor.py
-> factor_runner.run_single_factor
-> factor_builder.build_tick_order_size_factor
-> ch_tick.fetch_tick_agg_by_date_range
-> ch_tick.aggregate_wide_to_narrow
-> factor_runner._save_narrow
-> factor_narrow.parquet
```

这是当前代码的标准生成路径；仓库内既有 `factor_narrow.parquet` 生成于修正前，未被本报告复用。报告版审计路径为：

```
build_mid_order_ratio_strict_cache.py
-> corrected_ch_tick.fetch_tick_bucketed
-> tick_bucketed_strict_trade_2023-01-01_2024-06-30.parquet
-> generate_mid_order_ratio_report_artifacts.py
```

窄表字段：

字段	含义
symbol	Wind 股票代码
tradetime	交易日 + 09:30 的日频标记
factorname	mid_order_ratio
value	中单成交额 / 总成交额

09:30 是日频窄表的统一标记，不代表因子在当日 09:30 已知。因子使用全天成交，必须到收盘后才能完整计算；回测通过下一交易日对齐解决这一点。

8. No look-ahead

交易日 T-1 的 mid_order_ratio 需要汇总该日收盘前全部严格成交，因此只能在 T-1 收盘后完整获得。验证中统一使用：

```
signal = factor.shift(1)
```

即 T-1 因子解释 T 日 close-to-close return。ST、涨跌停和停牌状态在因子形成日应用后随信号一起滞后，避免使用 T 日结束后才可确认的信息。日度 RankIC、decile、H-L 和所有稳健性检验均使用相同对齐。


9. 因子分布

严格成交缓存覆盖 1,805,656 个沪深 A 股股票日：

统计量	因子值
Mean	0.2553
Std	0.0835
1% / 99%	0.0751 / 0.4398
25% / Median / 75%	0.1985 / 0.2583 / 0.3114

因子是 [0, 1] 内的比例变量，主体分布集中，不依赖极端大值。报告版不对原始因子 winsorize；中性化函数只对市值解释变量做 MAD 处理。

从 CSI1000 逐日成分的成交金额分布看，4万至20万元区间合计约占总成交额 30.2%，是有足够质量的中间分档，而不是极小尾部。



该图按成交金额加权，不是按成交笔数加权。

10. 旧口径与严格口径影响审计

报告版没有复用旧 value 列，而是从重新抽取的严格成交累计金额桶构造：

$$(cum_200000 - cum_40000) / TotalAmount$$

与旧 factor_narrow.parquet 的共同股票日比较：

- 匹配行：463,087 / 463,102；
- Pearson：0.8287；
- Spearman：0.7996；

- 平均绝对差: 0.0349;
- 99% 分位绝对差: 0.1485;
- 仅 0.99% 的共同记录在 10^{-12} 内相同。

差异来自输入记录筛选修正，而不是比例公式改变。旧面板不能继续作为“等价重构”或正式证据。所有 headline、图表、中性化和稳健性结果统一使用严格缓存；其 SHA256 为 ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f。

03 — Standalone Signal Validation

3.1 RankIC

Validation design

每天在 CSI1000 point-in-time 有效股票截面计算：

$$IC_t = \mathrm{Spearman} \left(\mathrm{MidOrderRatio}_{i,t-1}, r_{i,t}^{c2c} \right)$$

其中：

$$r_{i,t}^{c2c} = \frac{Close_{i,t}}{PreClose_{i,t}} - 1$$

Spearman RankIC 使用排名而非原始尺度，因此主要检验因子能否预测下一交易日的横截面收益排序。所有结果均使用 T-1 信号、同一可交易性规则和 250 日年化。

IC statistics

Statistic	Raw factor result	Effective-direction equivalent
Mean RankIC	-4.80%	+4.80%
Daily IC std	11.99%	11.99%
IC t-stat	-7.58	+7.58
Annualized ICIR	-6.33	+6.33
Direction-consistent day ratio	IC < 0 on 67.9% of days	IC > 0 on 67.9% of days
Valid days	358	358

负号是经济方向，不是有效性否定：

raw mid_order_ratio higher
→
next-day cross-sectional return rank lower
effective signal = -mid_order_ratio


这里三个不同层次，不能混为一谈：

- 1. 统计含义： IC(f,r)<0 只说明高 raw factor 对应较低的未来收益排序；

2. 方向标准化：factor library 同时保留 raw definition 和 effective_direction=-1，于是用于统一画图和构造 H-L 的信号为 -f。取负号不改变信息量、显著性或经济事实，只改变“高分是否代表高预期收益”的展示约定；


3. 机制解释：为什么高占比对应较低次日收益，不能由 IC 的符号本身推出。流动性压力、临时价格影响和反转均是后续待验证假说，而不是取负号的数学理由。

因此，-mid_order_ratio 应理解为预测方向元数据，不是一个经过额外加工后才“变得有效”的新因子。该方向在进入新样本外窗口前必须冻结，不能随新窗口表现反复翻转。



Daily raw RankIC

日度 IC 存在明显波动，但分布中心稳定落在 0 左侧。普通日度 t-stat 未调整自相关，因此本报告把它视为基础显著性证据，不把它解释为完整统计推断。



IC distribution

分布两侧均有尾部，说明该关系不是逐日确定规律；均值、方向一致日占比与时间稳定性需要联合阅读。

3.2 Decile Analysis

Sorting convention

每天按有效方向 `-mid_order_ratio` 从低到高分成十组：


```
G1 = effective signal lowest
    = raw mid_order_ratio highest

G10 = effective signal highest
     = raw mid_order_ratio lowest
```

图中单组收益为：

```
stock close-to-close return
- CSI1000 index close-to-close return
= CSI1000 index-excess return
```


曲线是日超额收益的 `cumulative sum`，不是绝对收益或复利净值。该检验只用于观察单因子排序与尾部分离，不构成任何配置建议。



CSI1000 index-excess decile cumulative return

Annualized decile return table

Effective decile	Raw-factor meaning	Annualized CSI1000 index-excess return
G1	highest mid_order_ratio	-30.07%
G2	higher	-15.51%
G3		+3.89%
G4		+8.21%
G5		+5.95%
G6		+11.48%
G7		+10.48%
G8		+10.22%
G9	lower	+12.05%
G10	lowest mid_order_ratio	+11.05%



Source: same daily series as cumulative decile figure • arithmetic annualization • fee=0.

CSI1000 annualized decile returns

将组号 1, \ldots, 10 与上表全样本年化指数超额收益做 Spearman 相关，得到：

$$\begin{aligned} & \rho_{\{\mathrm{decile}\}} \\ &= \\ & \mathrm{Spearman}(\mathrm{group}, \overline{r_{\{\mathrm{group}\}}}) \\ &= \\ & \mathbf{0.879} \end{aligned}$$

该数字是聚合 decile monotonicity diagnostic，机器结果见 artifacts/csi1000_decile_summary.csv，并可由日度 decile artifact 重算；它不是“87.9% 的日期单调”，也不能替代日度 RankIC。G10-G1 年化端点差为 41.12 个百分点，但中间组并非严格逐级单调，且 G9 略高于 G10。因此证据支持“尾部区分度较强、总体排序方向一致”，不支持“完美单调”。

3.3 H-L Spread

有效方向 H-L 定义为：

H-L

=

$r_{G10}-r_{G1}$

Metric	Result	Definition
Arithmetic annual return	41.12% gross	日均 H-L $\times$ 250
Sharpe	2.74 gross	$\text{mean} / \text{sample std} \times \sqrt{250}$, risk-free rate = 0
Maximum drawdown	-9.68%	基于 H-L 日收益复利路径
Daily turnover	1.69	G10 与 G1 相邻日权重变化绝对值之和

H-L 是对单因子横截面排序能力的两端诊断。其年化差中，高 raw factor 组的显著负超额贡献较大；不能只把它理解为低 raw factor 端的表现。

这里的换手定义没有除以 2：

$\mathrm{TO}^{\mathrm{H-L}}_t$

=

$$\sum_i |w^{\mathrm{G10}}_{i,t}-w^{\mathrm{G10}}_{i,t-1}|$$
$$+$$
$$\sum_i |w^{\mathrm{G1}}_{i,t}-w^{\mathrm{G1}}_{i,t-1}|$$

例如，一条满仓腿卖出旧持仓的 50% 并买入等额新持仓，其绝对权重变化和为 1.0；若多空两腿都发生同样替换，H-L turnover 为 2.0。因此 1.69 表示两条单位权重腿合计的日均绝对权重变化，不等于“每天更换 169% 的股票数量”。

若仅作量纲敏感性锚点，以每单位换手 7.5 bps 机械相乘，则隐含年化成本负担约为 $1.6884\times7.5\mathrm{bps}\times250=31.66\%$ 。这不是成本后回测：它没有处理佣金结构、冲击、容量、涨跌停或执行时点，只说明高换手会显著限制 gross spread 的可交易外推。

所有 H-L 指标均为 fee=0 gross。手续费、滑点、市场冲击和执行约束没有进入当前验证，因此这些数值只用于判断预测关系的强度和稳定性。

3.4 Exact-EW long-book diagnostic

H-L 可以检验两端排序，但会同时受 long 端和 short 端影响。作为补充，代码还直接计算有效 G10 相对当日有效 CSI1000 股票等权组合的 excess return，而不是用十组收益均值近似 benchmark：

Metric	Exact-EW G10 result
Annualized excess return	8.32% gross
Excess Sharpe	1.41 gross
Maximum drawdown	-3.84%
Average G10 names	99.5

这个 long-book diagnostic 明显弱于 H-L Sharpe 2.74，进一步说明 headline H-L 的一部分来自高 raw factor 端的负收益。它仍是 fee=0、每日等权重构的研究诊断，不是生产组合结论。

3.5 Standalone validation conclusion

CSI1000 证据在三个层面一致：

- 1. raw RankIC 均值为负且 t-stat 显著；
- 2. 十分组总体按有效方向上升，两端分离明显；
- 3. H-L 路径具有正的风险调整诊断值，但换手较高。

因此当前样本支持 mid_order_ratio 具有统计显著的 standalone cross-sectional predictive relationship。该判断不依赖任何其他因子的加入。

04 — Robustness Analysis

本章只检验单因子结论是否依赖特定股票池、阈值、日期或交易活跃状态。所有检验沿用同一 `strict-trade` 数据、T-1 对齐和 `raw/effective direction` 约定。

4.1 Cross-universe robustness

指数股票池使用 Wind 日度成分，而不是样本期成分并集。`artifact` 中的 `ALL` 仅指沪深交易所 A 股：Wind 收益面板与严格因子面板的当日有效交集，不包含北交所。

Point-in-time universe 是什么

对每个因子形成日 $t-1$ ，代码读取该日 Wind 权重表中的真实历史成员集合 $U_{\{t-1\}}$ ，先施加成员与可交易性掩码，再将完整信号整体滞后到收益日 t ：

$$S_{\{i, t\}} = f_{\{i, t-1\}} \cdot \mathbf{1}_{\{i \in U_{\{t-1\}}\}} \cdot \mathbf{1}_{\{i \text{ tradable at } t-1\}}$$

因此，2023 年的测试不会使用 2024 年或当前的 CSI1000 名单回填历史。若改用“样本期最终名单”或当前名单，后来被调出、退市或不再满足指数条件的股票会被系统性遗漏，造成 `survivorship bias`。PIT 处理解决的是历史成员身份口径；它不等于成本、可成交容量或样本外验证。

这里还有一个实现细节：成员掩码取信号形成日 $t-1$ ，并与信号一起 `shift` 到 t ，不是事后使用收益日收盘才确认的集合。SSE/SZSE A-share 没有固定成分表，其每日 `universe` 定义为当日严格因子、Wind 收益和可交易性数据的有效交集。

Universe	Raw RankIC	Raw ICIR	Effective H-L Sharpe	H-L MDD	H-L turnover
SSE/SZSE A-share	-5.53%	-7.29	3.05	-20.51%	1.73
CSI300	-2.12%	-3.34	1.26	-9.90%	1.68
CSI500	-3.45%	-4.43	1.49	-9.57%	1.72
CSI1000	-4.80%	-6.33	2.74	-9.68%	1.69

mid_order_ratio — Point-in-Time Universe Comparison
RankIC is raw direction; H-L is effective direction and exact-universe-EW excess

Universe	Avg names	Date range	RankIC	ICIR	H-L Sharpe	H-L MDD	H-L TO
SSE/SZSE A	4,840	2023-01-04 2024-06-28	-5.53%	-7.29	3.05	-20.51%	1.73
CSI300	299	2023-01-04 2024-06-28	-2.12%	-3.34	1.26	-9.90%	1.68
CSI500	497	2023-01-04 2024-06-28	-3.45%	-4.43	1.49	-9.57%	1.72
CSI1000	990	2023-01-04 2024-06-28	-4.80%	-6.33	2.74	-9.68%	1.69

Source: OH strict-trade L4w/920w cache • Wind PIT membership/returns • daily c2c • T-1 signal • 2023-01-01 to 2024-06-30.

Universe comparison

四个 `universe` 的 `raw RankIC` 均为负，说明预测方向不是 CSI1000 特有。强度具有规模层级差异：CSI300 最弱，SSE/SZSE A-share 与 CSI1000 更强。因此可以判断方向具有跨股票池一致性，但不能假定强度在所有市值层级相同。

4.2 Parameter sensitivity


阈值网格为：

Lower bound L ∈ {2, 3, 4, 5, 6} 万元
Upper bound H ∈ {10, 15, 20, 25, 30} 万元


每个单元使用：

Ratio(L, H)
=
 $\frac{\text{CumAmount}(H) - \text{CumAmount}(L)}{\text{TotalAmount}}$

并在同一 CSI1000 PIT 样本、T-1 信号和评估函数下重新计算。



ICIR parameter sensitivity



H-L Sharpe parameter sensitivity


Metric across 25 cells	Observed range
Raw Rank IC	-5.12% to -4.22%
Raw ICIR	-6.93 to -6.02
Effective H-L Sharpe	2.53 to 3.81
Effective H-L annual gross	37.28 to 50.04%

25 个单元全部保持负 IC，且相邻阈值变化平滑，没有只有有一个孤立点有效的尖峰。L2w/H15w 的样本内 Sharpe 高于事前定义 L4w/H20w，但本报告不据此修改因子定义：

- 1. 4万/20万是事前研究口径；
- 2. 网格与主验证使用同一历史样本；
- 3. 选择样本内最高结果会引入 multiple-testing bias。

参数网格用于检验邻域稳定性，不用于寻找“最优参数”。

4.3 Time stability



IC stability diagnostics

Time-stability diagnostic	Result
Negative-IC months	16 / 18
Strongest negative month	2024-04, -9.39%
Largest positive month	2024-02, +3.10%
Full-sample RankIC	-4.80%
RankIC excluding 2024-01	-4.79%


日度 IC 波动较大，但 63 日滚动均值大部分时间低于 0；月度均值在 18 个月中有 16 个月为负。删除 2024-01 后均值仅变化 0.01 个百分点，说明结果不是由该月单独推动。

2024-02 和 2024-06 的非负月份同时表明该因子存在阶段性失效，不能描述为无条件规律。18 个月仍不足以覆盖完整市场周期。


4.4 State dependence

每天使用已知于 T-1 的 20 日平均 log turnover，将 CSI1000 有效股票分为三个状态，并在各状态内部计算 raw RankIC：

Lagged turnover tercile	Raw RankIC	Raw ICIR	IC < 0 day ratio	Valid days
Low	-1.35%	-2.12	55.8%	328
Mid	-2.70%	-4.67	61.6%	328
High	-5.60%	-7.10	67.1%	328



Turnover state versus IC



Signal strength varies across trading activity environments. 高换手状态中的 IC 约为低换手状态的 4.1 倍，但三个状态的分布仍有重叠，因此 turnover 是条件变量而不是确定性开关。状态变量使用样本前 60 个日历日预热，并在收益日前再滞后一天。

这里的 turnover 只用于回答“预测关系在何种交易活跃环境中更强”，不改变 mid_order_ratio 的定义。

4.5 Robustness conclusion

当前样本支持：

- raw IC 方向不依赖单一 universe；
- raw IC 方向不依赖单一合理阈值；
- 结果不由单月或少数日期完全驱动；
- 信号强度随交易活跃环境变化。

这些检验提高了 standalone signal 的可信度，但不替代更长历史和真正样本外验证。

05 — Factor Exposure Diagnostics

本章不引入其他预测因子，也不构造联合信号。行业、市值和风格变量只作为解释变量，用于检验 `mid_order_ratio` 的预测关系是否可被常见特征完全解释。

5.1 Industry-dummy and Size Regression Residualization

逐日 CSI1000 PIT 截面回归：

```
Factor_{i,t}
:=
\alpha_t
+\sum_j \gamma_{j,t} IndustryDummy_{i,j,t}
+\beta_t \log(MarketCap_{i,t})
+\varepsilon_{i,t}
```


以残差 `\varepsilon_{i,t}` 重新进行同一 T-1 standalone validation。三种诊断分别删除：

- 1. Industry residual: `OLS(factor ~ intercept + CITICS Level-1 dummies)`;
- 2. Market-cap residual: `OLS(factor ~ intercept + standardized log total market cap)`;
- 3. Industry + market-cap residual: 在同一个每日截面回归中同时加入行业哑变量和市值。

市值变量进行 MAD 异常值处理和标准化；原始 `mid_order_ratio` 不 winsorize。

这里的“行业中性化”不是行业中位数扣除。对只有行业哑变量的回归，拟合值对应各行业截面均值，因此残差在数值上等价于行业均值去除；加入市值后则是联合 OLS 残差化。报告不解释单个行业回归系数，只使用残差检验预测关系是否仍存在。

Method	Raw-direction RankIC	Raw ICIR	Effective H-L Sharpe	H-L MDD	Absolute IC retained
Raw	-4.80%	-6.33	2.74	-9.68%	100%
Industry	-4.62%	-9.53	4.17	-6.62%	96%
Market cap	-4.52%	-5.82	2.42	-10.05%	94%
Industry + market cap	-4.41%	-9.09	4.42	-7.22%	92%



Industry and size exposure diagnostic

行业和规模处理后，raw-direction RankIC 仍为负且保留 92% - 96% 的绝对幅度。行业相关处理使日度 IC 标准差下降，因此 ICIR 和部分 H-L 路径指标改善；这不表示中性化“创造了信息”，也不构成选择更高 Sharpe 版本的依据。

为什么 industry + cap 后 Sharpe 从 2.74 升至 4.42

Sharpe 的变化应同时看均值和波动，而不能只读一个比率：

H-L component	Raw	Industry + market cap
Arithmetic annual gross return	41.12%	40.62%
Implied annualized volatility (annual return / Sharpe)	15.00%	9.20%
Gross Sharpe	2.74	4.42
Absolute RankIC	4.80%	4.41%

样本内平均 spread 没有增加，绝对 RankIC 反而略降；Sharpe 上升主要对应 H-L 日收益波动约下降 38.7%。一个与结果一致的解释是，行业与规模残差化减少了非目标截面共变，使排序路径更集中。但这只是样本内分解：组合成员和尾部排序也会随残差化改变，不能据此断言被删除的暴露必然是“噪声”，更不能把差值解释为被创造出来的 Alpha。是否能稳定降低风险仍需冻结方法后的样本外检验。

研究结论是：

行业和规模解释了部分因子水平差异，但不能完全解释 mid_order_ratio 与次日收益之间的横截面预测关系。

Cross-universe exposure check

每个 universe 均在其当日 PIT 成员内部重新估计回归，而不是套用 CSI1000 系数：

Universe	Raw	Industry residual	Cap residual	Industry + cap residual
SSE/SZSE A-share	-5.53%	-5.38%	-5.68%	-5.45%
CSI300	-2.12%	-1.41%	-3.49%	-2.09%
CSI500	-3.45%	-3.15%	-3.47%	-3.25%
CSI1000	-4.80%	-4.62%	-4.52%	-4.41%

16 组 RankIC 全部为负，说明“行业或规模完全造成主结论”的解释在四个股票池中均不成立。完整机器结果保留于 artifacts/neutralization_by_universe.csv；本报告不依据其中最高样本内 Sharpe 选择因子版本。

5.2 Style residual tests

在 CSI1000 industry + cap residual 基础上，再分别删除以下特征的线性解释：


- 20 日 momentum;
- 20 日 volatility;
- 20 日平均 log turnover。

三个控制变量均使用样本开始前 60 个日历日预热。每个 residual 版本只与完全相同股票日支持集上的 industry + cap baseline 比较，避免把控制变量缺失导致的样本变化误算成“被解释的 IC”。turnover 源覆盖较窄，因此其 matched comparison 有 332 个有效日；momentum 和 volatility 为 358 日。

该诊断只回答：

在相同样本支持上，mid_order_ratio 的剩余预测关系在多大程度上可被这些特征的线性项解释？

Residual test	Valid days	Matched baseline Rank IC	Residual Rank IC	Raw ICIR	Effective H-L Sharpe	Absolute IC retained
Baseline: industry + cap	358	-4.41%	-4.41%	-9.09	4.42	100%
Remove momentum	358	-4.41%	-4.07%	-8.29	4.13	92%
Remove volatility	358	-4.41%	-2.80%	-6.74	3.58	63%
Remove turnover	332	-4.76%	-2.33%	-5.24	3.41	49%



Momentum

删除 momentum 后保留约 92% 的绝对 IC，短期趋势不是主关系的充分解释。

Volatility

删除 volatility 后保留约 63%，说明成交规模结构与波动状态共享部分信息。

Turnover

在相同 332 日支持集上，删除 turnover 后绝对 RankIC 从 -4.76% 降至 -2.33%，保留约 49%，是三个特征中解释幅度最大的变量。这与状态检验中“高换手股票的 raw IC 更强”一致。

正确表述是：交易活跃度可以解释预测关系的一部分，但不能在当前线性残差检验中解释全部关系。该结果不证明任何变量之间的因果顺序。

5.3 Exposure diagnostic conclusion

1. 行业与规模不是主结果的充分解释；
2. momentum 的解释幅度较小；
3. volatility 的解释幅度中等；
4. turnover 的解释幅度最大；
5. 所有残差版本仍保持原始负向 IC。

因此，mid_order_ratio 可以继续作为 standalone research candidate；其经济解释必须明确包含交易活跃度条件。

06 — Economic Interpretation

6.1 Observed fact

本研究直接观察到：

Higher mid_order_ratio predicts lower next-day cross-sectional return rank.

在 CSI1000 PIT 样本中，raw RankIC 为 -4.80%；SSE/SZSE A-share（不含北交所）、CSI300、CSI500 和 CSI1000 的方向一致。最高 raw mid_order_ratio 的有效 G1 组指数超额年化化为 -30.07%，最低 raw mid_order_ratio 的有效 G10 组为 +11.05%。

这是统计关系，不是已识别的因果链条。

6.2 What the factor measures

mid_order_ratio 描述一只股票当天总成交额中，单笔金额位于人民币（4万，20万】的成交占比。它观测的是 transaction-size composition。

它不直接观测：

- 主动买入或主动卖出；
- 订单簿深度；
- 账户身份；
- 交易动机；
- 同一订单是否被拆分。

Transaction size does not identify investor type. 大型账户可以拆单，小型账户也可能产生较大成交，因此不能把该金额区间机械对应到任何交易者群体。

6.3 Possible explanation 1 — Short-term liquidity pressure

如果中等金额成交集中出现，它可能伴随一段方向一致的流动性需求。流动性供给者吸收需求时，价格可能暂时偏离短期均衡。当前证据链应画成：

```
Observed:
mid-order amount share high
-----> next-day return rank lower

Hypothesized mechanism:
mid-order amount share high
-> concentrated signed execution flow
-> same-day temporary price pressure
-> next-day partial reversal

Missing measurements:
active buy/sell direction + intraday price path + overnight/open-to-close decomposition
```

图中只有第一条关系被当前 RankIC 直接观测，下面三步均待验证。尤其“反转”要求先证明高占比伴随同方向的当日价格冲击：若主要是买方临时冲击，次日负收益可以与回撤一致；若主要是卖方临时冲击，标准反转机制反而预期次日正收益。因子未使用主动买卖方向或当日价格路径，所以当前报告不能确认压力方向，也不能仅凭 IC 把关系命名为 reversal。

6.4 Possible explanation 2 — Temporary price impact

成交规模构成可能反映当日冲击的执行方式。若中等金额成交更频繁地伴随短期、非基本面驱动的交易，高占比可能对应更强的临时价格影响，并在下一日出现均值回归。

该机制可解释：

- raw factor 与下一日收益的负向关系；
- 信号在高换手状态中更强；
- 分组区分主要集中于两端而非完全线性。

但当前验证没有分离当日永久冲击与临时冲击，也没有检验高占比与当日收益方向的条件关系，更没有分解隔夜和次日盘中路径。因此这里只能称为待检验的候选解释；信息延续、风险补偿或遗漏状态变量也可能产生相同的负 RankIC。

6.5 Possible explanation 3 — Transaction-size composition

mid_order_ratio 不是总成交额或平均单笔金额，而是成交金额分布中一个区间的质量占比。相同日成交额可以由不同的逐笔金额构成，这种组成差异可能对应不同的短期交易环境。

状态检验显示：

Lagged turnover state	Raw RankIC
Low	-1.35%
Mid	-2.70%
High	-5.60%

在共同的 332 日支持集上，行业+规模 matched baseline 的 RankIC 为 -4.76%，进一步删除 turnover 后为 -2.33%，保留约 49%。两项证据共同说明，交易活跃度解释了部分关系，但成交规模构成本身在该线性检验后仍保留负向预测关系。

6.6 Why the effect is stronger in the tails

CSI1000 decile 的中间组不是严格单调，而最高 raw factor 端的负超额最明显。一种保守解释是：只有当成交规模构成显著偏离常态时，其短期信息才足够强；中间区域包含更多相互抵消的交易动机。

这仍是统计描述。要验证该假说，需要个股历史分位标准化、极端事件研究以及主动买卖方向分解。

6.7 Most defensible interpretation

mid_order_ratio 衡量中等金额逐笔成交在总成交额中的参与强度。历史样本中，高中等金额成交占比与较低下一交易日收益排序相关，且关系在高交易活跃状态中更强。短期流动性压力和临时价格影响是与部分证据相容、但尚未完成方向与价格路径验证的候选机制；成交金额不能识别交易者身份，当前实证关系既不构成因果证明，也不足以单独证明反转。

应避免：

- 把中等金额成交直接等同于特定账户类型；
- 声称因子证明了知情交易或市场操纵；

- 把平均统计关系表述为每日确定规律；
- 从历史相关性直接推出交易指令。

07 — Limitations and Future Research

7.1 Sample period length

主样本为 2023-01 至 2024-06，共 358 个有效交易日和 18 个自然月。月度与滚动检验可以排除“单月完全驱动”，但不能覆盖完整市场周期。

当前尤其缺少：

- 更早年份的不同波动与流动性环境；
- 重大制度变化前后的统一 Tick schema 验证；
- 2024-07 之后的真正样本外观察；
- 多年连续的年度稳定性结果。

25 单元参数网格与主结果使用同一历史样本，因此参数邻域稳定不是样本外验证。

7.2 No long historical validation

严格成交定义要求交易所 Tick 字段在历史上保持可解释。深市 Type、BidOrderNo、AskOrderNo 以及上交所 Amount 的长期 schema 一致性尚未在多年范围内完成逐年核验。

当前 artifact key ALL 只覆盖 SSE/SZSE A 股代码，不含北交所；因此不能把该结果外推为包含 BSE 的完整全市场结论。

在延长样本前，需要先确认：

1. 每年真实成交的识别规则；
2. Price、Volume、Amount 的单位与缺失处理；
3. 股票、ETF、可转债代码边界；
4. 两交易所因子分布是否存在 feed-driven break。

7.3 Transaction costs are not modeled

headline H-L Sharpe 为 fee=0 gross，日均 turnover 为 1.69。手续费、滑点、市场冲击、涨跌停和成交量约束均未建模。

该 turnover 是两端组合绝对权重变化之和，未除以 2；它不能直接读成“169% 的股票被替换”。按 7.5 bps / 单位换手机械估算的 31.66% 年化负担只能作为量纲敏感性锚点，不是成本后业绩。

因此：

- H-L 只用于 standalone sorting diagnostic；
- gross Sharpe 不能解释为成本后结果；
- 本报告不提供交易频率、资金规模或权重结论。

交易成本缺失不改变 RankIC 的统计定义，但限制对 H-L 路径的经济外推。

7.4 No causal identification

逐笔成交金额不能识别：

- 账户类型；
- 同一订单是否拆分；
- 主动买卖方向；
- 真实交易动机；
- 价格变化是永久冲击还是临时冲击。

因此“高中单占比导致次日下跌”不是当前证据支持的表述。当前结果只证明样本内条件相关和排序预测关系。

7.5 Statistical inference limits

当前 t-stat 使用普通日度均值标准误，未做 Newey-West 自相关调整；参数、universe、状态和 exposure diagnostics 共检验了多个切片。

这些切片用于检验合理稳健性，而不是选择最高结果，但 multiple-testing 风险仍存在。后续应预注册新的样本范围与主指标，并增加：

- Newey-West t-stat；
- block bootstrap confidence interval；
- 年度分层结果；
- 明确的样本外冻结窗口。

7.6 Data extraction and reproducibility limits

正式结果统一使用 strict-trade cache，记录了日期、行数、交易所规则和 SHA256。旧 factor_narrow.parquet 与严格面板的 Spearman 只有 0.7996，已明确标为 legacy evidence。

仍需持续记录：

- query hash；
- 源表分区版本；
- extraction timestamp；
- construction code commit；
- 每年每交易所 row count 与 checksum。

7.7 Future research

Extend the sample

1. 将严格口径样本延伸至 2024-07 之后；
2. 在 schema 可核验前提下尽可能回溯至 2019 或更早；
3. 按年份和重大市场阶段报告 raw RankIC 与方向一致日占比；
4. 预注册扩展样本，不根据新结果修改 4万/20万定义。

Test longer return horizons

检验 T+1、T+2、T+5、T+10 和 T+20 RankIC decay，区分：

- 一日反转；
- 多日缓慢修复；

- 短期关系是否在更长 horizon 消失或反向。

Active buy/sell decomposition

在交易所字段语义可核验后，使用 BSFlag、BidOrderNo 和 AskOrderNo 区分：

- active-buy medium trades;
- active-sell medium trades;
- directionally signed medium-amount flow。

这可以检验负向关系是否主要来自买方冲击后的回撤、卖方压力后的修复，或无方向的成交规模组成。

Order-flow direction and price path

进一步分解：

- 当日价格冲击；
- overnight gap；
- 次日开盘至收盘；
- 次日盘中反转；
- 极端 mid_order_ratio 事件窗口。

该研究可以提高机制辨识度，但不会改变本报告的 standalone factor definition。

7.8 Final boundary

当前证据支持：

构造经严格审计、在当前样本中具有统计显著预测关系、通过合理稳健性检验，并具有可解释但未被证明的经济机制。

当前证据不支持：

- 已完成长期历史验证；
- 已识别因果机制；
- 已获得成本后结论；
- 已完成充分样本外验证。

因此，mid_order_ratio 的合理定位是 research candidate / candidate alpha feature。值得继续进行更长历史、样本外、更多收益 horizon 和方向性订单流验证。Further portfolio integration is outside the scope of this report.

08 — Research Decision Framework

本章把前述结果转化为 research-grade single factor library 的证据门。它不是把所有指标压成一个总分，而是要求关键失败项不能被其他亮眼指标抵消。

8.1 Decision tree

```
Factor definition frozen before evaluation?
no -> redesign definition; do not compare performance
yes
|
v
Raw-data semantics and construction audit passed?
no -> stop; rebuild data and invalidate downstream results
yes
|
v
T-1 alignment and point-in-time universe verified?
no -> stop; remove look-ahead / survivorship contamination
yes
|
v
Standalone IC significant and direction stable?
no -> archive or reformulate hypothesis
yes
|
v
Cross-universe, parameter-neighborhood and time checks survive?
no -> retain only as conditional / regime-specific evidence
yes
|
v
Signal survives pre-specified exposure residual tests?
no -> relabel as known exposure proxy
yes
|
v
Turnover, cost and capacity acceptable for intended use?
no -> research feature only; no tradability claim
yes
|
v
Frozen out-of-sample validation passed?
no -> research candidate
yes -> validated candidate for portfolio-level evaluation
```

“stop” 表示不能继续把后续回测数字当作该因子的有效证据，不表示永久删除研究想法。例如本项目发现 legacy Tick 构造失败后，正确动作是重建 strict cache 并从头重算，而不是用后续 Sharpe 为错误输入辩护。

8.2 Current gate status

Evidence gate	Current status	Decision basis
Frozen definition	Pass	(4万, 20万] 是事前既有公式; 未改用样本内 Sharpe 最高网格
Data semantics and construction	Pass for current sample	strict SSE/SZSE execution filters、 逐日时段条件、单测、checksum; legacy 结果作废
Timing and PIT universe	Pass for current design	全天因子 shift(1); 历史日度成员在信号形成日应用
Standalone prediction	Pass in sample	raw RankIC -4.80%, t-stat -7.58, 67.9% 日期方向一致
Decile structure	Conditional pass	聚合单调性 0.879、两端分离清晰; 中间组不严格单调
Robustness	Pass within available sample	四股票池同方向、25 阈值单元同方向、 16/18 个月负 IC
Exposure diagnostics	Pass as residual test	行业+市值后保留 92% 绝对 IC; matched sample 删除 turnover 后仍保留约 49%
Economic mechanism	Plausible, unverified	缺少主动方向、当日冲击和收益路径, 不能识别因果或反转
Cost and capacity	Not passed	H-L turnover 1.69; headline 为 fee=0; 7.5 bps 机械成本锚点约 31.66%/年
Frozen out-of-sample	Not passed	正式 strict 样本止于 2024-06, 尚无冻结后的新窗口

当前决策不是“可交易 Alpha”，而是：

Retain as a research candidate / candidate alpha feature. 构造、时序、
样本内预测与合理稳健性证据已通过；成本、容量、长期 schema 和冻结样本外门尚未通过。

8.3 Library metadata that must travel with the factor

为了避免只保留一个因子值列而丢失研究语义，library entry 至少应保存：

- 1. raw name 与公式：mid_order_ratio = amount(4w, 20w] / total_amount;
- 2. 阈值边界：lower exclusive、upper inclusive;
- 3. raw/effective direction: raw RankIC 为负，effective_direction=-1;
- 4. 数据语义：交易所表、成交识别、金额字段、常规时段和时区；
- 5. availability: 完整日因子在收盘后已知，验证使用 shift(1)；
- 6. universe: PIT 成分来源及成员掩码应用日期；
- 7. headline metric definitions: RankIC、ICIR、decile、H-L、turnover、benchmark 和年化方式；
- 8. evidence version: 样本区间、strict cache SHA256、代码版本和 artifact 路径；

- 9. known limits: 短样本、无完整成本模型、无因果识别、无正式样本外;
- 10. promotion status: research_candidate, 不得静默标记为 production-ready。

8.4 Next decision-changing experiments

后续实验应优先关闭未通过的门，而不是继续增加同一样本内的切片：

- 1. 冻结公式、方向、中性化方法和主指标，扩展 2024-07 之后的样本外窗口；
- 2. 逐年审计 SSE/SZSE schema 后扩展多年 strict history；
- 3. 报告 T+1 至 T+20 decay、Newey-West 与 block-bootstrap 区间；
- 4. 使用可执行的换仓频率、双边费用、滑点、冲击和容量约束；
- 5. 加入主动买卖方向和日内价格路径，区分临时冲击、延续与反转。

只有这些结果通过后，才进入组合相关性、边际贡献和投资组合约束评估；组合集成不属于本报告的 standalone factor verdict。

Appendix A — 代码索引

1. ClickHouse Tick 聚合

l2_factor_reproduction/python/ch_tick.py

fetch_tick_agg_by_date_range (约第 95 行)

职责:

- 按日期范围从 SSE / SZSE Tick 表读取逐笔成交;
- 过滤交易时段、零价格和零成交量;
- 在 ClickHouse 内计算:
 - TotalAmount
 - MediumAmount
 - SmallAmount
- GROUP BY Symbol, TradeDate;
- 合并两交易所股票日结果。

关键金额口径:

```
SSE = ifNull(Amount, Price * Volume)
SZSE = Price * Volume
```

关键成交口径:

- SSE 使用 Type='T';
- SZSE 使用 Type='011' 且 BidOrderNo>0 AND AskOrderNo>0;
- _regular_session_filter_sql 对区间内每一行施加 09:30 - 15:00 条件;
- 该函数的输出是股票日聚合, 不是原始 Tick。

fetch_tick_bucketed (约第 187 行)

职责:

- 对多个订单金额阈值一次生成累计成交金额;
- 输出 cum_20000、cum_30000 ... cum_300000;
- 服务参数敏感性分析, 避免为 25 个参数重复扫描 Tick。

报告版重构:

```
mid_order_ratio(L, H)
= (cum_H - cum_L) / TotalAmount
```

与日常聚合路径相同, bucket 查询也使用逐日时段和交易所成交筛选, 避免参数分析与基础因子产生口径分叉。

aggregate_wide_to_narrow (约第 481 行)

职责:

- 将 `MediumAmount / TotalAmount` 转为因子值；
- 删除零分母和无效值；
- 输出统一窄表：
- `symbol`
- `tradetime`
- `factorname`
- `value`

2. 因子生成

`l2_factor_reproduction/python/factor_builder.py`

`_build_tick_order_size_factor`（约第 109 行）

职责：

1. 取得研究日期和 `universe`；
2. 调用 `_stock_pool_vector` 获取样本期指数成分并集；
3. 按日期块调用 `ClickHouse` 聚合；
4. 将股票日金额转为 `mid_order_ratio / small_order_ratio`；
5. 拼接并去重。

重要口径：

- 这里的股票列表是查询裁剪用的样本期成分并集；
- `point-in-time membership` 必须在正式回测阶段另行施加；
- `universe` 参数不是自动完成 PIT 回测的充分条件。

`build_factor`（约第 162 行）

统一入口：

- 根据 `FACTOR_BUILDERS` 注册表选择构造函数；
- 支持覆盖 `start_day`、`end_day` 和 `universe`；
- 对 `Tick` 因子进入 `ClickHouse` 构造路径，对其他 `L2` 因子进入相应 `DDB` 路径。

`l2_factor_reproduction/python/factor_runner.py`

`run_single_factor`（约第 61 行）

职责：

- 建立 `DDB` 客户端；
- 调用 `build_factor`；
- 可选保存到：

`research/results/l2_reproduction/<factor>/factor_narrow.parquet`；

- 确保会话关闭。

3. 回测评估

l2_factor_reproduction/python/backtest.py

prepare_factor_signal (约第 60 行)

职责:

- 窄表 pivot 为 Date × Symbol;
- 对齐收益和可交易性掩码;
- 使用 `signal.shift(1)`;
- 返回已滞后信号和收益矩阵。

现有基础路径默认收益为 CSI1000 index-excess; 它不自动应用逐日 index membership。

compute_rank_ic (约第 87 行)

逐日:

```
signal.corrwith(ret, axis=1, method="spearman")
```

输出日度 RankIC Series。

summarize_backtest (约第 91 行)

汇总:

- RankIC mean / std / ICIR;
- H-L annual return;
- H-L Sharpe;
- H-L MDD;
- turnover;
- factor direction。

注意检查 summary 字段是 raw direction 还是 effective direction。报告版专用脚本将两者明确分开。

backtest_factor (约第 130 行)

主流程:

1. narrow_to_wide;
2. prepare_factor_signal;
3. 根据 IC 符号确定方向;
4. Factor_Dev_Lib.groupTest;
5. summarize_backtest。

save_group_plots (约第 201 行)

生成旧版 cum_pnl.png 和 decile_bar.png。旧标题没有完整写明 benchmark、PIT/union 和 cumsum 口径, 因此正式报告未直接发布这些图。

`_save_backtest_outputs` (约第 288 行)

保存:

- `group_pnl.csv`
- `group_turnover.csv`
- `rank_ic.csv`
- `summary.json`
- 基础图表。

4. 一阶中性化

`I2_factor_reproduction/scripts/test_neutralization.py`

职责:

- 读取 `raw factor narrow`;
- 调用 `Factor_Dev_Lib.panel_neutral_size_ind`;
- 支持:
 - `ind`
 - `cap`
 - `ind_cap`
- 对每个 `residual panel` 重新运行同一回测;
- 输出 `neutralization_comparison.csv`。

依赖:

- CITICS 一级行业;
- Wind 总市值;
- 每日截面 OLS。

5. 二阶中性化

`I2_factor_reproduction/python/neutralization.py`

`neutralize_again` (约第 16 行)

在已有 `residual` 上分别对指定风格特征做逐日截面回归并取残差。

`I2_factor_reproduction/scripts/test_double_neutralization.py`

构造并检验:

- 20 日 `momentum`;
- 20 日 `volatility`;
- 20 日平均 `log turnover`;
- 分别输出三个单特征残差诊断。

`l2_factor_reproduction/scripts/screen_second_pass.py`

输出可直接比较的二阶中性化摘要，如：

```
second_pass_screen_ind_cap.csv
```

这些旧产物使用 CSI1000 样本期成分并集且依赖修正前的 canonical factor，因此不进入正式报告。报告生成器从严格 cache 在 CSI1000 PIT 面板上重新计算三个二阶残差。

6. 周度诊断

`l2_factor_reproduction/scripts/optimize_weekly.py`

职责：

- 选取每周首个交易日形成新权重；
- 周内持有；
- 对比 daily 与 weekly 的 gross、turnover 和展示性成本。

该脚本用于研究信号持续性，不构成交易频率建议；本报告 headline 不使用其结果。

7. 参数敏感性

`l2_factor_reproduction/scripts/analyze_param_sensitivity.py`

职责：

- 调用 `fetch_tick_bucketed`；
- 构造 5×5 L/H 网格；
- 运行 RankIC、ICIR、H-L 和 turnover；
- 生成基础 heatmap。

原脚本未施加 PIT index membership。正式报告由专用脚本读取同一 bucket cache，并在每个网格单元应用 CSI1000 日度成员。

8. 状态依赖

`l2_factor_reproduction/scripts/analyze_state_dependence.py`

职责：

- 从 Wind 获取 turnover；
- 计算 20 日平滑状态；
- 按横截面 tercile 分组；
- 计算组内 RankIC。

正式报告专用版本将 turnover state 再滞后一天，避免以 T 日已实现换手率解释 T 日收益。

9. 时间稳定性

`l2_factor_reproduction/scripts/analyze_time_stability.py`

职责：

- 读取日度 RankIC；
- 生成月度平均；
- 生成滚动 IC；
- 生成 IC 分布。

正式报告使用 PIT CSI1000 重新计算的 `csi1000_rank_ic_daily.csv`，不直接复用 union 版本。

10. 基础运行入口

`l2_factor_reproduction/scripts/run_single_factor.py`

命令行参数：

- `--factor`
- `--start`
- `--end`
- `--universe`
- `--no-backtest`
- `--no-save`

它串联：

```
factor_runner.run_single_factor
-> backtest.backtest_factor
-> _save_backtest_outputs
```

11. 正式报告专用生成器

`l2_factor_reproduction/scripts/build_mid_order_ratio_strict_cache.py`

本次新增的修正缓存构建器：

1. 从 Wind 收益面板取得候选代码，最终报告范围限定为 SSE/SZSE A 股；
2. 按季度调用已修正的 `fetch_tick_bucketed`；
3. 不覆盖旧 cache，保存 `strict-trade` 分块和合并 `parquet`；
4. 写入筛选规则、行数、日期和 SHA256 元数据。

`l2_factor_reproduction/scripts/generate_mid_order_ratio_report_artifacts.py`

本次新增的审计脚本，职责：

1. 校验 `strict metadata`、筛选语义和 SHA256 后，从冻结 `bucket cache` 重构沪深 A 股 L4w/H20w；
2. 加载 Wind raw c2c 和可交易掩码；

3. 施加 SSE/SZSE (artifact key ALL) / CSI300 / CSI500 / CSI1000 PIT universe;
4. 输出同口径 universe comparison;
5. 以冻结 effective_direction=-1 重算四股票池 × 四方法的一阶中性化矩阵, 以及 CSI1000 PIT decile、decile monotonicity、IC、parameter grid 和 state dependence;
6. 二阶 neutralization 使用样本前预热, 并为每个 style residual 计算完全相同股票日支持上的 matched baseline;
7. 生成全部自描述图;
8. 保存 artifact manifest 和 legacy-vs-strict 构造影响审计。

它不会修改原始 Tick 表, 也不会覆盖 research/results/l2_reproduction/mid_order_ratio/ 的旧研究记录。


`l2_factor_reproduction/scripts/export_mid_order_ratio_report.py`

将 README、八章正文和三个附录按固定顺序合并:

1. 用 Mistune 生成带目录、内嵌图表和本地 MathJax 的 HTML;
2. 用 Matplotlib 生成 A4 分页、嵌入中文字体的 PDF;
3. 输出至 research/reports/factors/mid_order_ratio/export/;
4. 不修改共享 Python/Conda 环境。

Appendix B — 数据血缘

1. 血缘总览



2. ClickHouse 上游

Item	Value
Config key	COMMON_CONST. DATA_DB_HFDATA
Host	10. 80. 139. 9
Port	8123
Database	cmds
SSE table	cmds. SSE_AL_TICK_EXG
SZSE table	cmds. SZSE_AL_TICK_EXG
Python client	clickhouse_connect

2026-08-04 连接自检 SELECT 1 成功。源表审计时可见：

- SSE Tick: 2015-01-05 至 2026-08-03;
- SZSE Tick: 2008-01-02 至 2026-08-03。

该覆盖描述源表总体，不表示所有 A 股、所有字段在每一天完整。

3. DolphinDB 上游

Item	Value
Config key	COMMON_CONST. DATA_DB_CONN
Host	10.12.180.9
Port	8902
Shared session	core/ddb/connection.py::get_ddb_session

2026-08-04 连接自检 1+1 返回 2。

主要 Wind 表：

Data	DDB source	Use
A-share EOD	dfs://WIND.ASHAREEODPRICES	raw c2c returns
CSI300 weights	dfs://WIND.AINDEXHS300WEIGHT	PIT members
CSI500 weights	dfs://WIND.AINDEXCSI500WEIGHT	PIT members
CSI1000 weights	dfs://WIND.AINDEXCSI1000WEIGHT	PIT members
Index EOD	Wind index EOD table	CSI1000 index-excess
ST status	Wind special-treatment data	signal-date mask
Trading status	Wind trading status data	suspension mask
Limit prices	Wind EOD limit information	limit mask
Industry	CITICS level-1	industry neutralization
Market cap	Wind valuation	log-cap neutralization
Turnover	Wind S_DQ_TURN	state/style analysis

4. Tick 字段级血缘

Raw field	Transformed field	Final use
ExchTime	TradeDate=toDate(ExchTime)	stock-day key
ExchTime	regular-session filter	exclude pre-open records
Price	amt	amount calculation
Volume	amt	amount calculation
Amount	SSE amt primary value	amount calculation
BSFlag	none	not used by mid_order_ratio
BidOrderNo	SZSE execution predicate	require both order numbers > 0
AskOrderNo	SZSE execution predicate	require both order numbers > 0

SSE:

```
amt = ifNull(Amount, Price * Volume)
Type = 'T'
```

SZSE:

```
amt = Price * Volume
Type = '011'
BidOrderNo > 0 and AskOrderNo > 0
```

5. Why L2 provides additional information

```
Same daily OHLCV:

Stock A: 100m traded amount
mostly <=20k prints
medium-band share low

Stock B: 100m traded amount
mostly 40k - 200k prints
medium-band share high

OHLCV sees:      A == B
Minute bars may see: similar intraday path
L2 Tick sees:    different transaction-size composition
```

L2 的增量信息不是“更多价格点”本身，而是逐笔成交金额分布和订单级属性。

6. 服务端聚合

Input key

```
(raw table, ExchTime, Symbol)
```

Filters

```
09:30:00 <= ExchTime < 15:00:01
Price > 0
Volume > 0
SSE Type = 'T'
SZSE Type = '011'
SZSE BidOrderNo > 0 and AskOrderNo > 0
```

Aggregation key

```
(TradeDate, Symbol)
```

Aggregated fields

```
TotalAmount
MediumAmount
SmallAmount
cum_20000 ... cum_300000
```

Final formula

```
value = MediumAmount / TotalAmount
       = (cum_200000 - cum_40000) / TotalAmount
```

Output key

```
(symbol, tradetime, factorname)
```

7. Legacy 因子产物

```
research/results/l2_reproduction/mid_order_ratio/factor_narrow.parquet
```

Property	Value
Rows	463,102
Symbols	1,303
First factor date	2023-01-03
Last factor date	2024-06-28
Mean factor value	0.2903
Median	0.3012

该文件来自修正前查询，且股票列表是样本期 CSI1000 成分并集。它同时受多日时段和深市成交识别问题影响，正式报告不把它作为因子源或日度 universe。

8. 报告版冻结 cache

```
research/results/l2_reproduction/mid_order_ratio/analysis/param_sensitivity/tick_bucketed_strict_trade_2023-01-01_2024-06-30.parquet
```

严格 cache：

- 1,805,656 个沪深 A 股股票日；
- 5,174 个有成交因子代码；
- 2023-01-03 至 2024-06-28。

缓存构建器先从 Wind 收益面板取得 5,175 个候选代码，再在仅含 SSE/SZSE 的 ClickHouse Tick 表中执行严格成交过滤。artifact 的 ALL universe 实际是沪深 A 股交集，不含北交所；每日平均最终有效 4,840 只。

元数据：

```
tick_bucketed_strict_trade_2023-01-01_2024-06-30.metadata.json
SHA256 = ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f
```

报告版 universe、decile、参数和状态结果都来自该冻结 cache。

9. Legacy-vs-strict 构造影响审计

严格累计桶面板与旧窄表的共同股票日：

Check	Result
Matched rows	463,087 / 463,102
Pearson	0.8287
Spearman	0.7996
Mean absolute difference	0.0349
99% absolute difference	0.1485
Share within 10 ⁻¹²	0.99%

这不是快照级微小误差，而是旧输入记录筛选不正确造成的实质变化。公式保持不变，但 legacy 产物已被严格 cache 取代。

机器结果：

- artifacts/construction_crosscheck.json
- artifacts/construction_crosscheck_top100.csv

10. 深市成交与交易时段修正审计

对 2024-06-27 的 697 只样本深市股票：

Item	Result
Legacy positive-price/volume rows	29,836,521
Strict execution rows	11,916,224
Legacy amount	RMB 370.77bn
Strict execution amount	RMB 93.19bn
Strict / legacy amount	25.13%
Factor Spearman	0.858
Mean absolute factor difference	0.0864

只比较 Type='011' 与其他 Type 会得到近乎相等的错误结论，因为非成交事件也位于 011 内。双订单号条件才是关键。另在 1,293 只样本股上核验到盘前/盘后金额占代表日总额约 2.52%；因此 SQL 还必须逐日施加时段条件。

机器记录：artifacts/strict_trade_filter_audit.json。该文件保留汇总数字和过滤口径，但原始 symbol list / query snapshot 未在首次审计时冻结；这是已披露的复现限制。

11. 收益与信号对齐

```
Factor date t:
  full-session tick aggregation
  signal-date tradability and membership mask

Return date t+1:
  signal.shift(1)
  raw c2c stock return
  optional common benchmark subtraction
```

主 decile figure:

```
stock raw c2c - CSI1000 index c2c
```

四 universe H-L:

```
stock raw c2c - exact valid-universe EW c2c
```

RankIC 和 H-L 对每日公共基准平移不敏感，单个 decile 收益敏感。

12. 最终产物血缘

```
artifacts/universe_comparison.csv
  <- PIT members + raw returns + reconstructed factor

artifacts/csi1000_decile_index_excess_daily.csv
  <- CSI1000 PIT signal + CSI1000 index-excess returns

artifacts/csi1000_decile_summary.csv
  <- daily decile artifact + arithmetic annualization + cross-decile Spearman

artifacts/strict_trade_filter_audit.json
  <- one-off SZSE execution/session filter materiality audit
```

```
artifacts/neutralization_comparison.csv
  <- strict raw/ind/cap/ind_cap panels + CSI1000 PIT evaluation

artifacts/neutralization_by_universe.csv
  <- 4 universe-specific PIT panels × 4 locally re-estimated variants

artifacts/second_neutralization_comparison.csv
  <- strict ind+cap residual + prewarmed PIT style controls + matched-cell baselines

artifacts/parameter_sensitivity_csi1000_pit.csv
  <- cumulative amount buckets + 25 threshold definitions

artifacts/state_dependence_summary.csv
  <- PIT signal + prewarmed and lagged 20-day turnover terciles

figures/*.png
  <- only the machine-readable artifacts above
```

Appendix C — 复现命令

1. 环境

```
cd /home/SiYangGao/factor_dev/factor_research0703/factor_dev
PY=/opt/conda/anaconda3/envs/base_93/bin/python
```

运行需要访问内网：

- ClickHouse 10.80.139.9:8123
- DolphinDB 10.12.180.9:8902

2. 连接自检

```
$PY -c "
from core.ddb.connection import get_ddb_session, close_shared_ddb_session
import clickhouse_connect
from COMMON_CONST import DATA_DB_HFDATA

s = get_ddb_session()
print('DDB:', s.run('1+1'))
close_shared_ddb_session()

c = clickhouse_connect.get_client(**DATA_DB_HFDATA)
print('CH:', c.query('SELECT 1').result_rows[0][0])
c.close()
"
```

预期：

```
DDB: 2
CH: 1
```

3. 基础因子构造与 canonical 回测

```
$PY l2_factor_reproduction/scripts/run_single_factor.py \
--factor mid_order_ratio \
--start 2023-01-01 \
--end 2024-06-30
```

输出：

```
research/results/l2_reproduction/mid_order_ratio/
├── factor_narrow.parquet
├── group_pnl.csv
├── group_turnover.csv
├── rank_ic.csv
├── summary.json
├── cum_pnl.png
└── decile_bar.png
```

注意：当前代码已使用严格时段和交易所成交筛选，但该基础命令的查询 universe 仍是样本期成分并集，回测没有自动施加逐日 membership。旧图也没有完整标注 benchmark，不应直接替代正式报告图。仓库中现存 canonical 文件可能早于修正；只有重新执行本命令后才会更新。

4. 一阶中性化

```
$PY I2_factor_reproduction/scripts/test_neutralization.py \  
--factor mid_order_ratio \  
--neutral_types ind cap ind_cap
```

输出:

```
research/results/I2_reproduction/mid_order_ratio/  
├── neutralized_ind/  
├── neutralized_cap/  
├── neutralized_ind_cap/  
└── neutralization_comparison.csv
```

5. 二阶中性化

```
$PY I2_factor_reproduction/scripts/test_double_neutralization.py \  
--factor mid_order_ratio  
  
$PY I2_factor_reproduction/scripts/screen_second_pass.py \  
--factor mid_order_ratio
```

关键输出:

```
research/results/I2_reproduction/mid_order_ratio/  
├── second_pass_screen_ind.csv  
└── second_pass_screen_ind_cap.csv
```

6. 周度持续性诊断

```
$PY I2_factor_reproduction/scripts/optimize_weekly.py \  
--factor mid_order_ratio \  
--raw  
  
$PY I2_factor_reproduction/scripts/optimize_weekly.py \  
--factor mid_order_ratio
```

该模块是频率/换手研究，不属于本报告 headline。

7. 原参数、状态和时间脚本

```
$PY I2_factor_reproduction/scripts/analyze_param_sensitivity.py \  
--start 2023-01-01 \  
--end 2024-06-30  
  
$PY I2_factor_reproduction/scripts/analyze_state_dependence.py \  
--factor mid_order_ratio  
  
$PY I2_factor_reproduction/scripts/analyze_time_stability.py \  
--factor mid_order_ratio
```

原参数脚本不施加 CSI1000 日度 membership；正式报告版通过下一节命令重算。

8. 构建严格成交缓存

```
$PY I2_factor_reproduction/scripts/build_mid_order_ratio_strict_cache.py \
--start 2023-01-01 \
--end 2024-06-30
```

输出:

```
research/results/I2_reproduction/mid_order_ratio/analysis/param_sensitivity/
├── strict_trade_chunks_2023-01-01_2024-06-30/
├── tick_bucketed_strict_trade_2023-01-01_2024-06-30.parquet
└── tick_bucketed_strict_trade_2023-01-01_2024-06-30.metadata.json
```

脚本不会覆盖 legacy cache; 已验证缓存 SHA256 为 ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f。

9. 一键生成正式报告 artifacts 与图

```
$PY I2_factor_reproduction/scripts/generate_mid_order_ratio_report_artifacts.py \
--start 2023-01-01 \
--end 2024-06-30 \
--bucket-cache \
research/results/I2_reproduction/mid_order_ratio/analysis/param_sensitivity/tick_bucketed_strict_trade_2023-01-01_2024-06-30.parquet \
--output-root \
research/reports/factors/mid_order_ratio
```

该脚本约完成:

1. 从 strict-trade bucket cache 重构 L4w/H20w 沪深 A 股面板;
2. 构造 SSE/SZSE (artifact key ALL) / CSI300 / CSI500 / CSI1000 PIT universe;
3. 输出 universe comparison;
4. 生成 CSI1000 index-excess deciles;
5. 重算四股票池 × 四方法的 PIT 一阶中性化矩阵, 以及 CSI1000 二阶中性化;
6. 重算 25 单元 PIT 参数网格;
7. 使用 T-1 turnover state 重算 regime IC;
8. 生成月度、滚动和分布图;
9. 写入 legacy-vs-strict 构造影响审计。

10. 正式 artifacts

```
research/reports/factors/mid_order_ratio/artifacts/
├── artifact_manifest.json
├── construction_crosscheck.json
├── construction_crosscheck_top100.csv
├── strict_trade_filter_audit.json
├── factor_value_distribution_summary.csv
├── universe_comparison.csv
├── rank_ic_{all,csi300,csi500,csi1000}.csv
├── group_pnl_{all,csi300,csi500,csi1000}_ew_excess.csv
├── group_turnover_{all,csi300,csi500,csi1000}.csv
├── csi1000_rank_ic_daily.csv
├── csi1000_decile_index_excess_daily.csv
├── csi1000_decile_summary.csv
└── csi1000_decile_turnover_daily.csv
```

```
└── neutralization_comparison.csv
└── neutralization_by_universe.csv
└── second_neutralization_comparison.csv
└── parameter_sensitivity_csi1000_pit.csv
└── state_dependence_daily_ic.csv
└── state_dependence_summary.csv
└── time_stability_monthly_ic.csv
└── order_size_distribution.csv
```

11. 正式 figures

```
research/reports/factors/mid_order_ratio/figures/
└── 01_pipeline_architecture.png
└── 02_order_size_distribution.png
└── 03_universe_comparison_table.png
└── 04_decile_cumulative_csi1000_index_excess.png
└── 05_decile_annualized_csi1000_index_excess.png
└── 06_ic_time_series.png
└── 07_rolling_ic.png
└── 07b_ic_stability_combined.png
└── 08_neutralization_comparison.png
└── 08b_universe_neutralization_matrix.png
└── 09_second_neutralization_comparison.png
└── 10a_parameter_sensitivity_icir.png
└── 10b_parameter_sensitivity_sharpe.png
└── 11_turnover_vs_ic_relationship.png
└── 12_high_low_turnover_regime_comparison.png
└── 13_ic_distribution.png
└── 14_monthly_ic.png
```

12. 代码静态检查

```
$PY -m py_compile \
  l2_factor_reproduction/python/ch_tick.py \
  l2_factor_reproduction/scripts/build_mid_order_ratio_strict_cache.py \
  l2_factor_reproduction/scripts/generate_mid_order_ratio_report_artifacts.py

$PY -m pytest -q l2_factor_reproduction/tests/test_ch_tick.py
```

13. 结果一致性检查

```
$PY - <<'PY'
import pandas as pd
import json

root = "research/reports/factors/mid_order_ratio/artifacts"
u = pd.read_csv(f"{root}/universe_comparison.csv")
g = pd.read_csv(f"{root}/parameter_sensitivity_csi1000_pit.csv")
n = pd.read_csv(f"{root}/neutralization_by_universe.csv")
s = pd.read_csv(f"{root}/second_neutralization_comparison.csv")

assert set(u["universe"]) == {"ALL", "CSI300", "CSI500", "CSI1000"}
assert (u["rank_ic"] < 0).all()
assert len(g) == 25
assert (g["rank_ic"] < 0).all()
assert len(n) == 16
assert (n["rank_ic"] < 0).all()
assert set(n["method"]) == {
    "raw", "industry", "market_cap", "industry+market_cap"
}
assert (u["effective_direction"] == -1).all()
assert (n["effective_direction"] == -1).all()
```

```

assert (s["abs_ic_retained_vs_matched"].between(0, 1)).all()

paper = g.query("L_wan == 4 and H_wan == 20").iloc[0]
csi = u.query("universe == 'CSI1000'").iloc[0]
assert abs(paper["rank_ic"] - csi["rank_ic"]) < 1e-12
assert abs(paper["hl_sharpe"] - csi["hl_sharpe"]) < 1e-12

manifest = json.load(open(f"{root}/artifact_manifest.json"))
assert "strict_trade" in manifest["sources"]["bucket_cache"]
assert manifest["sources"]["bucket_cache_sha256"] == (
    "ccd2f23475756052c60c32f8b56b8cbb648ab99508bf866c9b2424b7ff61cb1f"
)
assert manifest["factor_definition"]["direction_policy"].startswith("frozen")
assert manifest["factor_definition"]["szse_trade_filter"] == (
    "Type='011' AND BidOrderNo>0 AND AskOrderNo>0"
)

print("verified")
PY

```

14. 阅读顺序

复现后先检查：

1. construction_crosscheck.json;
2. universe_comparison.csv;
3. neutralization_by_universe.csv;
4. csi1000_decile_index_excess_daily.csv;
5. csi1000_decile_summary.csv 的 monotonicity 是否可由日度 decile 重算;
6. 图 04 标题是否仍明确写 CSI1000 Index-Excess Return;
7. parameter_sensitivity_csi1000_pit.csv 的 L4w/H20w 是否与 CSI1000 headline 相等;
8. artifact_manifest.json 的日期、cache 和 metric conventions。

15. 导出整份报告

```
$PY l2_factor_reproduction/scripts/export_mid_order_ratio_report.py
```

输出：

```

research/reports/factors/mid_order_ratio/export/
├── mid_order_ratio_report.html      # local assets MathJax
├── mid_order_ratio_report.pdf
├── public/index.html               # public single-file HTML
└── assets/mathjax/

```

public/index.html 是单文件版本：图表 base64 内嵌，公式用 CDN MathJax，可直接用浏览器打开或挂到任意静态站点。

```

# 本机可分享的 http 链接
cd research/reports/factors/mid_order_ratio/export/public
python3 -m http.server 8765 --bind 0.0.0.0
# 浏览器打开 http://<host>:8765/

```

HTML 合并全部正文与附录并内嵌图表；PDF 使用 A4 分页和嵌入式中文字体。无需修改共享 Conda 环境。